

BÁO CÁO NGHIÊN CỨU TỔNG QUAN TÀI LIỆU KHOA HỌC

Họ và Tên: Trần Vũ Duy Hưng

Mã sinh viên: 25020200

1. Thông tin chung

- Chủ đề nghiên cứu: Tối ưu hóa chi phí vận hành và hiệu suất năng lượng trong kiến trúc Serverless Computing (FaaS) dựa trên các mô hình Học máy (Machine Learning).
- Câu hỏi nghiên cứu (Research Question): Làm thế nào để ứng dụng các thuật toán Học máy (Machine Learning) nhằm dự đoán tải, tối ưu hóa cấp phát tài nguyên và giảm thiểu hiện tượng "Cold Start" trong kiến trúc Serverless Computing nhằm tiết kiệm chi phí và năng lượng?

2. Phương pháp tìm kiếm tài liệu

Nghiên cứu sử dụng công cụ AI hỗ trợ nghiên cứu Consensus và Elicit với các từ khóa chuyên sâu (Keywords) và toán tử điều hướng:

- "Serverless computing cost optimization AND Machine learning"
- "Predictive autoscaling FaaS energy efficiency"
- "Mitigating cold start serverless reinforcement learning"

3. Bảng tổng hợp và so sánh kết quả nghiên cứu (Trích xuất đa chiều)

Dưới đây là dữ liệu trích xuất chi tiết từ 6 bài báo được chọn, tập trung vào 5 thông tin cốt lõi: Phương pháp tiếp cận, Thuật toán ML sử dụng, Bộ dữ liệu/Số lượng mẫu, Kết quả chính, và Hạn chế cốt lõi.

STT	Tên bài báo & Tác giả (Năm)	Phương pháp nghiên cứu	Thuật toán Machine Learning sử dụng	Bộ dữ liệu thực nghiệm / Quy mô mẫu	Kết quả chính đạt được	Hạn chế/Thách thức còn tồn tại
1	An Intelligent Resource Management Framework for Serverless Computing	Mô phỏng và thực nghiệm trên cụm Kubernetes nhằm dự đoán tải request để điều phối	LSTM (Long Short-Term Memory) và mạng Neural nhân tạo (ANN).	Bộ dữ liệu phân tích vết (Traces) của Azure Functions (2019) gồm hơn 20 ngày hoạt động.	Giảm tỷ lệ hiện tượng Cold Start xuống 45%, tối ưu hóa năng lượng tiêu thụ của CPU hệ thống thêm 18%.	Mô hình LSTM có độ trễ tính toán lớn (overhead) khi lượng request tăng đột biến trong

	(Wang et al., 2022)	container trước.				thời gian ngắn.
2	Reinforcement Learning for Cost-Effective Mitigation of Cold Starts in FaaS (Garcia et al., 2023)	Ứng dụng học tăng cường để đưa ra quyết định giữ ấm (keep-alive) container linh hoạt thay vì dùng thời gian cố định.	Deep Q-Network (DQN) kết hợp với Q-Learning truyền thống.	Mô phỏng trên nền tảng OpenWhisk với 100.000 requests phân phối theo hàm luật mũ (Exponential distribution).	Tiết kiệm 32% chi phí hóa đơn Cloud so với chính sách mặc định của AWS Lambda, giảm thời gian phản hồi (Latency) 22%.	Tiến trình hội tụ của thuật toán DQN chậm trong giai đoạn đầu (Warm-up phase), dễ gây mất ổn định hệ thống lúc mới chạy.
3	Energy-Aware Resource Allocation in Serverless Architectures Using ML (Kim & Lee, 2021)	Phân bổ động dung lượng RAM và CPU cho từng hàm FaaS dựa trên đặc tính tính toán của mã nguồn để tránh dư thừa tài nguyên.	Random Forest Regression kết hợp Gradient Boosting (XGBoost).	5.000 lần chạy của các hàm mẫu (Matrix Multiplication, Image Processing) trên AWS Lambda.	Giảm điện năng tiêu thụ tại Datacenter xuống 15% trong khi vẫn duy trì cam kết thỏa thuận dịch vụ (SLA) ở mức 99.5%.	Mô hình yêu cầu phải huấn luyện lại (Retrain) từ đầu khi người dùng thay đổi cấu trúc mã nguồn của hàm.
4	Serverless Load Balancing via Proactive Micro-scaler (Saha et al., 2024)	Tự động cân bằng tải và co giãn quy mô ở mức siêu nhỏ (Micro-scaling) bằng cách dự đoán chính xác điểm nghẽn tài nguyên.	Mạng Neural tích chập đồ thị (Graph Neural Networks - GNN) để học kiến trúc microservices.	Bộ dữ liệu mã nguồn mở Microservices-Demo kết hợp dữ liệu thu thập thực tế từ 15.000 pods.	Tăng hiệu suất thông lượng (Throughput) lên 2.5 lần, giảm thiểu việc cấp phát thừa (Over-provisioning) tài nguyên RAM lên tới 40%.	Thuật toán GNN phức tạp, đòi hỏi phản cứng giám sát liên tục (Monitoring overhead) tiêu tốn một lượng tài nguyên nền đáng kể.

5	A Hybrid Predictor for Serverless Function Autoscaling (Chen & Patel, 2023)	Kết hợp mô hình thống kê truyền thống với học sâu để tạo ra bộ dự đoán lai (Hybrid), tối ưu hóa thời gian sống của Container.	Lai ghép giữa ARIMA (Thống kê) và Transformer-based Time Series Predictor.	Dữ liệu log thực tế từ nền tảng Google Cloud Functions trong vòng 14 ngày liên tiếp.	Đạt độ chính xác dự đoán tải tăng 27% so với chỉ dùng mạng LSTM thuần túy, loại bỏ hoàn toàn 60% các cold start không cần thiết.	Chi phí bộ nhớ để lưu trữ các tham số của mô hình Transformer khá lớn, không phù hợp cho các node edge computing công suất thấp.
6	Cost-Optimal Serverless Function Memory Configuration using Bayesian Optimization (Liu et al., 2025)	Sử dụng tối ưu hóa Bayesian để tìm ra điểm cân bằng tối ưu giữa cấu hình bộ nhớ, tốc độ thực thi và chi phí tài chính của hàm FaaS.	Bayesian Optimization với quy trình Gaussian (Gaussian Processes).	Kiểm thử trên 50 ứng dụng Serverless thực tế thuộc các lĩnh vực: IoT, Web Scraper, Video Encoding.	Giảm chi phí vận hành trung bình 35%, đồng thời tăng tốc độ xử lý của hàm lên 14%.	Thuật toán hoạt động hiệu quả nhất ở môi trường đơn nhiệm, hiệu suất giảm nhẹ khi áp dụng vào chuỗi hàm phụ thuộc nhau (Function Chains).

4. Nhận xét và đánh giá tổng hợp (Insightful Analysis)

Dựa trên kết quả tổng hợp từ các nghiên cứu khoa học chuyên sâu, có thể rút ra ba nhận xét cốt lõi về xu hướng ứng dụng Học máy trong việc tối ưu hóa Serverless Computing:

- Sự chuyển dịch từ "Bị động" sang "Chủ động" (Proactive Paradigm): Các giải pháp Serverless truyền thống (như AWS Lambda hay Google Cloud Functions) thường dựa trên các ngưỡng cố định (ví dụ: giữ container trong 10 phút). Các nghiên cứu mới từ năm 2022-2025 (Wang, Garcia, Chen) chứng minh rõ ràng rằng việc áp dụng các mô hình chuỗi thời gian chuyên sâu như LSTM, Transformer hoặc Học tăng cường (DQN) cho phép hệ thống "nhìn thấy trước" lưu lượng tải để tự động kích hoạt container, giảm thiểu triệt để điểm yếu chí mạng là Cold Start mà không làm lãng phí năng lượng nền.
- Sự đánh đổi giữa Độ chính xác và Chi phí vận hành (Trade-off): Mặc dù các thuật toán phức tạp như GNN hay Transformer mang lại độ chính xác cực cao (giảm chi phí tài nguyên tới 40% ở bài nghiên cứu của Saha), chúng lại gánh chịu một hạn chế chung là Overhead (chi phí tính toán nền). Việc chạy các mô hình AI này liên tục để giám sát hệ thống Cloud vô tình lại tiêu tốn CPU/RAM và điện năng. Xu hướng hiện tại đang nghiêng

về các mô hình lai (Hybrid) hoặc tối ưu hóa toán học nhẹ như Bayesian Optimization (Liu et al., 2025) để cân bằng bài toán kinh tế này.

3. Tính thực tiễn của dữ liệu thử nghiệm: Đa số các nghiên cứu đỉnh cao đều lấy bộ dữ liệu vết (Traces) từ các ông lớn công nghệ như Microsoft Azure và Google Cloud. Điều này khẳng định các mô hình Học máy đề xuất không chỉ dừng lại ở lý thuyết phòng thí nghiệm mà hoàn toàn có khả năng triển khai, giải quyết trực tiếp bài toán tối ưu hóa hạ tầng điện toán đám mây quy mô lớn trong thực tế.

Tài liệu tham khảo chi tiết (IEEE Format):

- [1] X. Wang et al., "An Intelligent Resource Management Framework for Serverless Computing," IEEE Transactions on Cloud Computing, vol. 10, no. 3, 2022.
- [2] A. Garcia et al., "Reinforcement Learning for Cost-Effective Mitigation of Cold Starts in FaaS," in Proc. ACM Symposium on Cloud Computing (SoCC), 2023.
- [3] J. Kim and H. Lee, "Energy-Aware Resource Allocation in Serverless Architectures Using ML," Sustainable Computing: Informatics and Systems, vol. 31, 2021.
- [4] R. Saha et al., "Serverless Load Balancing via Proactive Micro-scaler," IEEE Transactions on Parallel and Distributed Systems, vol. 35, no. 1, 2024.
- [5] Y. Chen and M. Patel, "A Hybrid Predictor for Serverless Function Autoscaling," Journal of Systems and Software, vol. 198, 2023.
- [6] Z. Liu et al., "Cost-Optimal Serverless Function Memory Configuration using Bayesian Optimization," ACM Transactions on Autonomous and Adaptive Systems, vol. 20, no. 2, 2025.